

Carga los datos y obtiene la información de las variables

En desarrollo (80%)

0.8

Feedback

Describe parcialmente el tipo de variables: ¿numéricas continuas o discretas? ¿categóricas nominales, ordinales o binarias?

De manera específica se está imprimiendo ahora por grupo de variables si estas son binarias, nominales, discretas o continuas. Dicho código está entre las líneas 91-131.

Procesamiento de las variables

alta desarrollar (50...

0.5

Feedback

La descripción parcial de las variables lo lleva a transformaciones parciales. En particular, la variable "mes" la transforma como ordinal, sin justificar por qué por ejemplo "marzo" es menos que "noviembre" al aplicar esta transformación.

Todas las variables fueron codificadas, se realizó la codificación en tres bloques como se muestra en las líneas 116-131 dependiendo de su naturaleza y se explica aquellas que tienen cierto orden. Las que presentaban sesgo y que hacían sentido desde el punto de vista de negocio se aplicó el logaritmo para eliminar sesgo. Todas las variables fueron estandarizadas.

Implementación de modelos.

alta desarrollar (50...

0.5

Feedback

Entrena con una familia de métricas sin justificar por qué se incluyen todas ellas, ni indicar cuál de ellas es la que será tomada para monitorear el mejor modelo. Y al hablar de mejor modelo, no verifica que se está yendo en esta dirección, es decir, ¿los modelos están subentrenados o sobreentrenados? En las conclusiones comenta que validación es parecido a entrenamiento, sin justificar de dónde obtiene particularmente dicha conclusión, cuál es el margen de diferencia para determinar que está o no sobreentrenado y nuevamente, sin indicar ni justificar la métrica que se haya seleccionado como el más importante para monitorear

En relación con las métricas en el despliegue de CONCLUSIONES, rendimiento final líneas 489-494, se establece los indicadores y su significado desde el punto de vista de negocio. En particular para F1 y ROAC-AUC, se cambiaron las leyendas. Las

primeras tres métricas se revisaron en el material de estudio y las otras dos se agregaron para tratar de contar con más elementos.

Para determinar que no hay sobreentrenamiento, de manera explícita se agregó la leyenda de la variación máxima y que gráfica observar. Se desplegó mensaje para indicar que no hay subentrenamiento y su razón.

El indicador para determinar el mejor modelo es el “accuracy_score” en las líneas 334-376 se determina que modelo seleccionar y hay un mensaje con la leyenda “COMPARACIÓN DE MODELOS” que muestra precisamente esos valores. Se decide por esta métrica considerando que no hay consecuencias financieras graves para un falso positivo o falso negativo.